مثال: الكتاب الذي قرأته اليوم كان جيدا

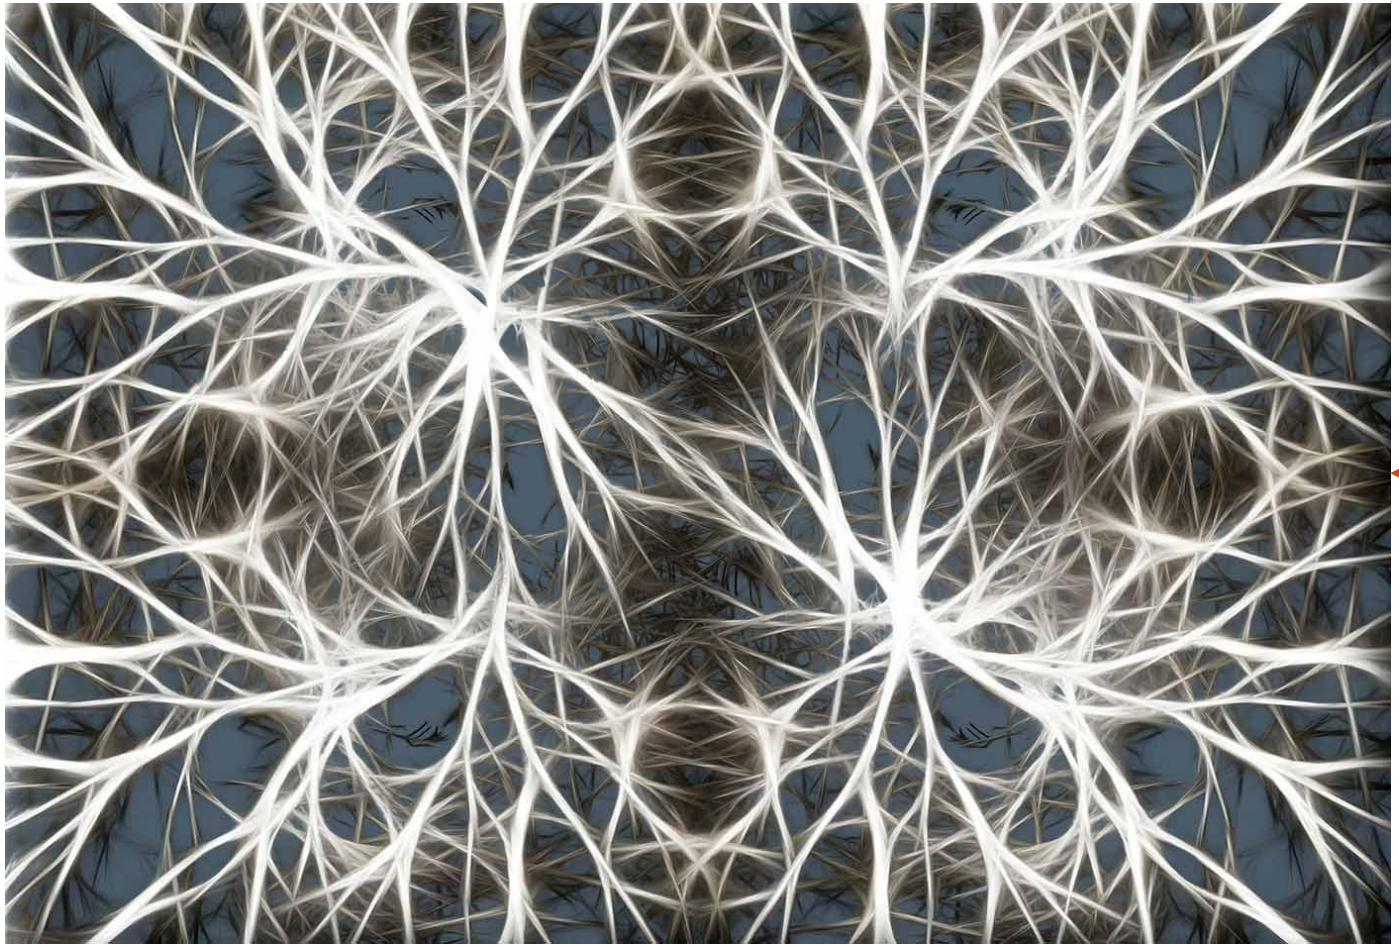

بسم الله الرحمن الرحيم

TOKENIZATION & EMBEDDING

م. يوسف مجدي

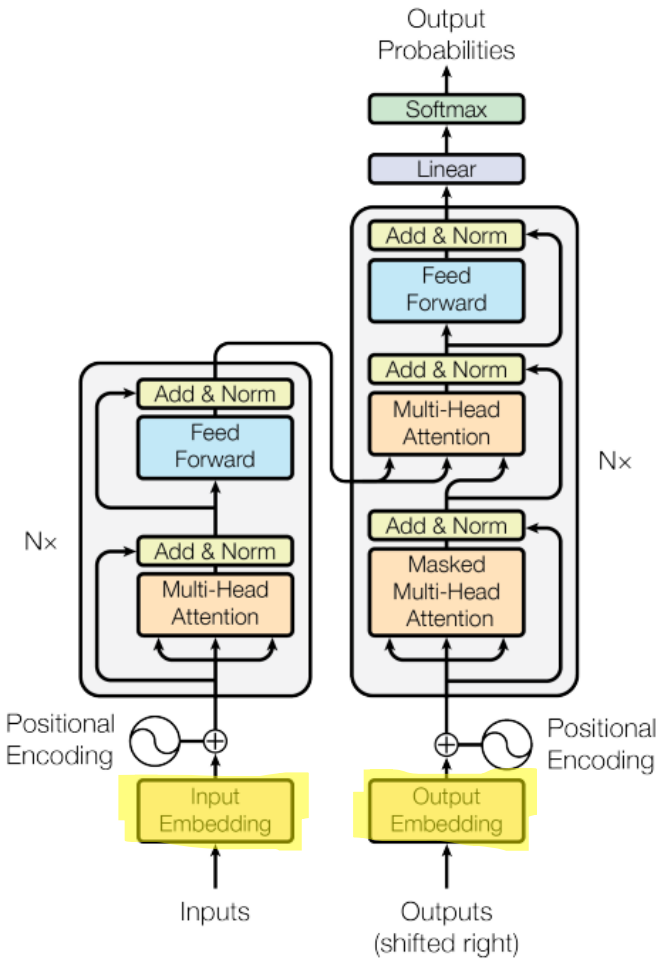

Figure 1: The Transformer - model architecture.

TOKENIZATION

مثال: الكتاب الذي قرأته اليوم كان جيدا

10,000 tokens

- الكتاب: 4189
- الذي: 212
- قرأته: 8213
- كان: 513
- جيدا: 1235
- .
- .
- .
- أنا: 1
- جميل: 12
- .
- .

28 tokens

- ا: 1
- ب: 2
- ت: 3
- ث: 4
- ج: 5
- .
- .
- .
- و: 27
- ي: 28

10,000 tokens

- ال: 4189
- كتاب: 1209
- الذي: 212
- قرأ: 8213
- ته: 340
- كان: 513
- جيد: 1235
- .
- .
- .

EMBEDDING

num_embd = 32

10,000 tokens

الكتاب: 4189
الذي: 212
قرأته: 8213
كان: 513
جيدا: 1235
.
.
.
أنا: 1
جميل: 12
.
.

32 number

-1.2
0.73
0.47
1.43
2.98
-2.12
-0.98
0.13
.
.

32 number

1.15
-1.73
-2.47
0.42
1.48
0.12
-0.12
-1.16
.
.

EMBEDDING

مثال: الكتاب الذي قرأته اليوم كان جيدا

10,000 tokens

الكتاب: 4189
الذي: 212
قرأته: 8213
كان: 513
جيدا: 1235
.
.
.
أنا: 1
جميل: 12
.
.

6 x 32

الكتاب	[0.12, 0.34, -2.9, ...]
الذي	[-1.22, 2.64, 0.9, ...]
قرأته	[1.33, 2.44, 1.87, ...]
اليوم	[2.32, -1.74, 1.69, ...]
كان	[-2.42, -1.54, -0.19, ...]
جيدا	[-1.32, 2.59, -1.19, ...]

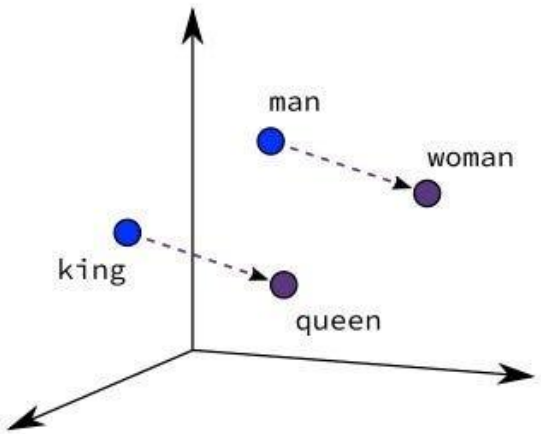

Male-Female

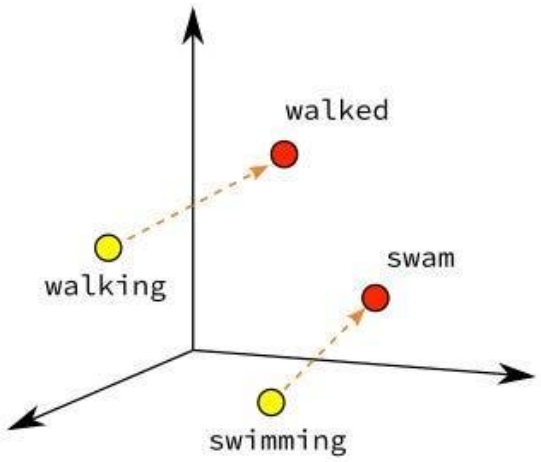

Verb Tense

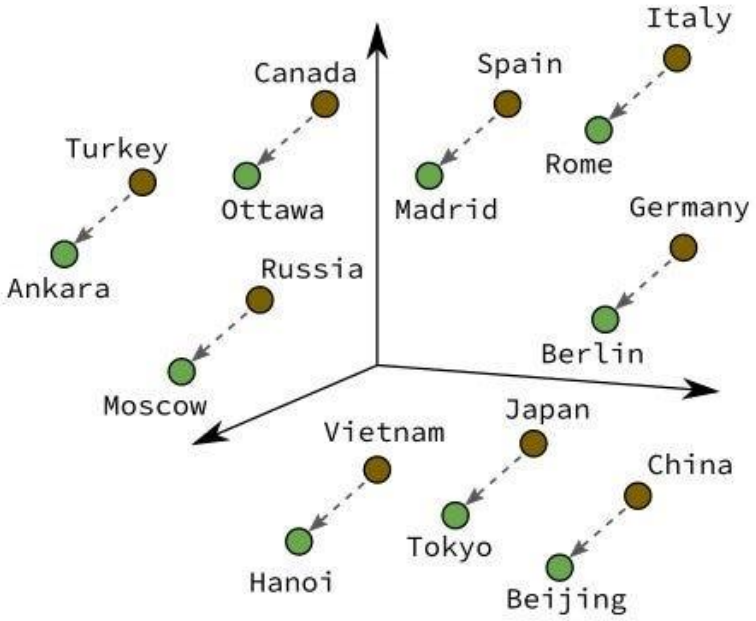

Country-Capital

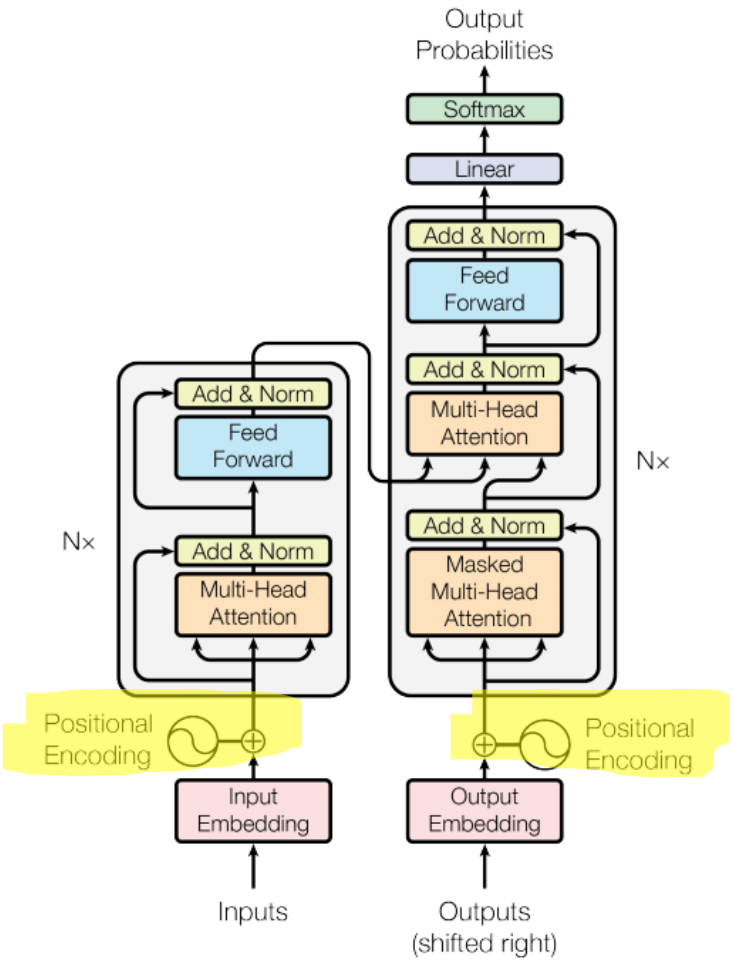

Figure 1: The Transformer - model architecture.

NEXT...ATTENTION