ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

Tokenization

10,000 tokens

الكتاب: 4189
الذي: 212
قرأته: 8213
كان: 513
جيدا: 1235
.
.
.
أنا: 1
جميل: 12
.
.

Embedding

6 x 32

الكتاب	[0.12, 0.34, -2.9, ...]
الذي	[-1.22, 2.64, 0.9, ...]
قرأته	[1.33, 2.44, 1.87, ...]
اليوم	[2.32, -1.74, 1.69, ...]
كان	[-2.42, -1.54, -0.19, ...]
جيدا	[-1.32, 2.59, -1.19, ...]

بسم الله الرحمن الرحيم

ATTENTION

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

*Equal contribution. Listing order is random. Jakob proposed replacing RNNs with self-attention and started

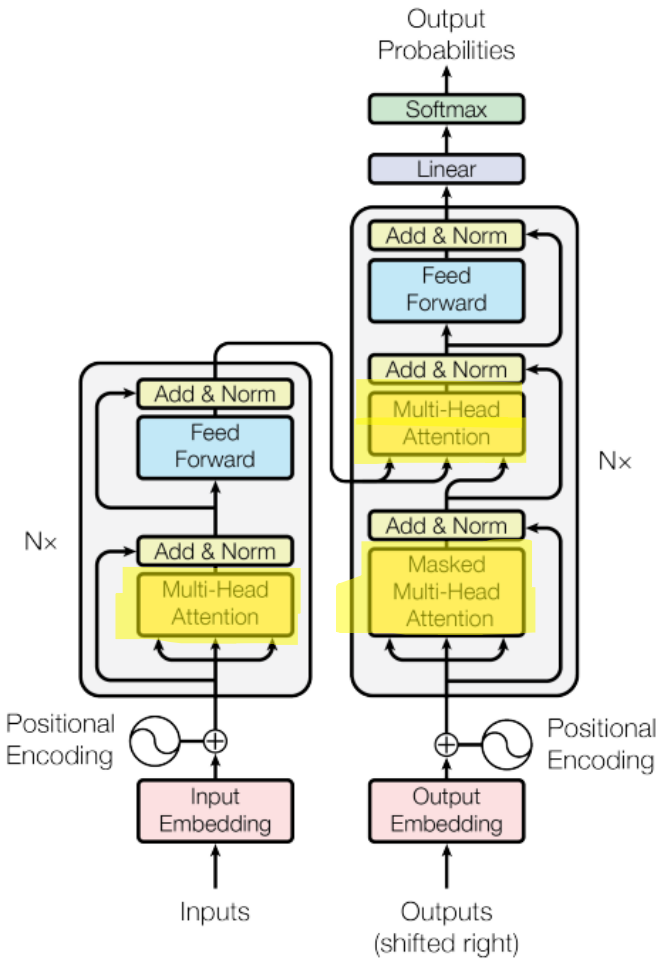

Figure 1: The Transformer - model architecture.

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

10,000 tokens

الكتاب: 4189
الذي: 212
قرأته: 8213
كان: 513
جيدا: 1235
.
.
.
أنا: 1
جميل: 12
.
.

n_tokens x n_embd

الكتاب	[0.12, 0.34, -2.9, ...]
الذي	[-1.22, 2.64, 0.9, ...]
قرأته	[1.33, 2.44, 1.87, ...]
اليوم	[2.32, -1.74, 1.69, ...]
كان	[-2.42, -1.54, -0.19, ...]
جيدا	[-1.32, 2.59, -1.19, ...]

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

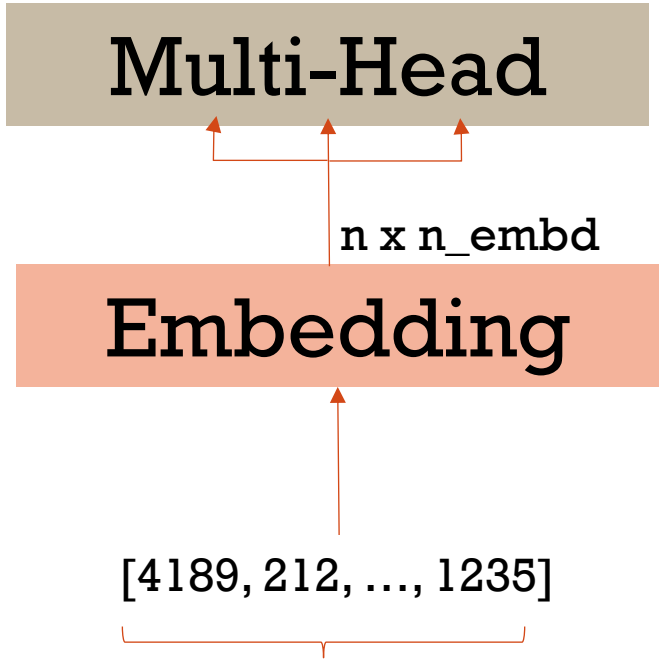

6 x 32

الكتاب	[0.12, 0.34, -2.9, ...]
الذي	[-1.22, 2.64, 0.9, ...]
قرأته	[1.33, 2.44, 1.87, ...]
اليوم	[2.32, -1.74, 1.69, ...]
كان	[-2.42, -1.54, -0.19, ...]
جيدا	[-1.32, 2.59, -1.19, ...]

ATTENTION

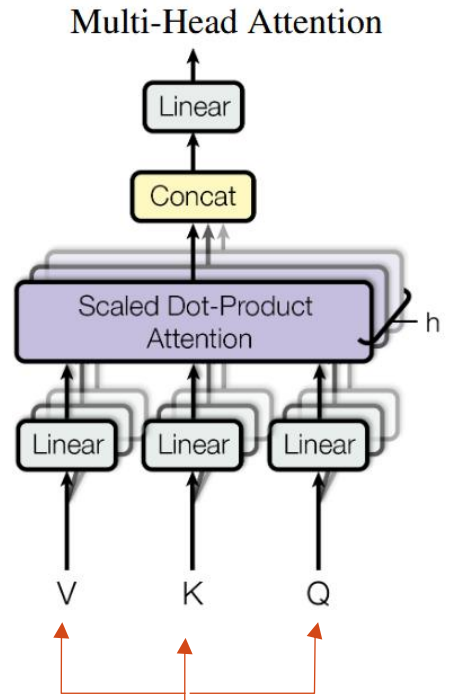

n x n_embd

[4189, 212, …, 1235]

n tokens

Embedding

ATTENTION

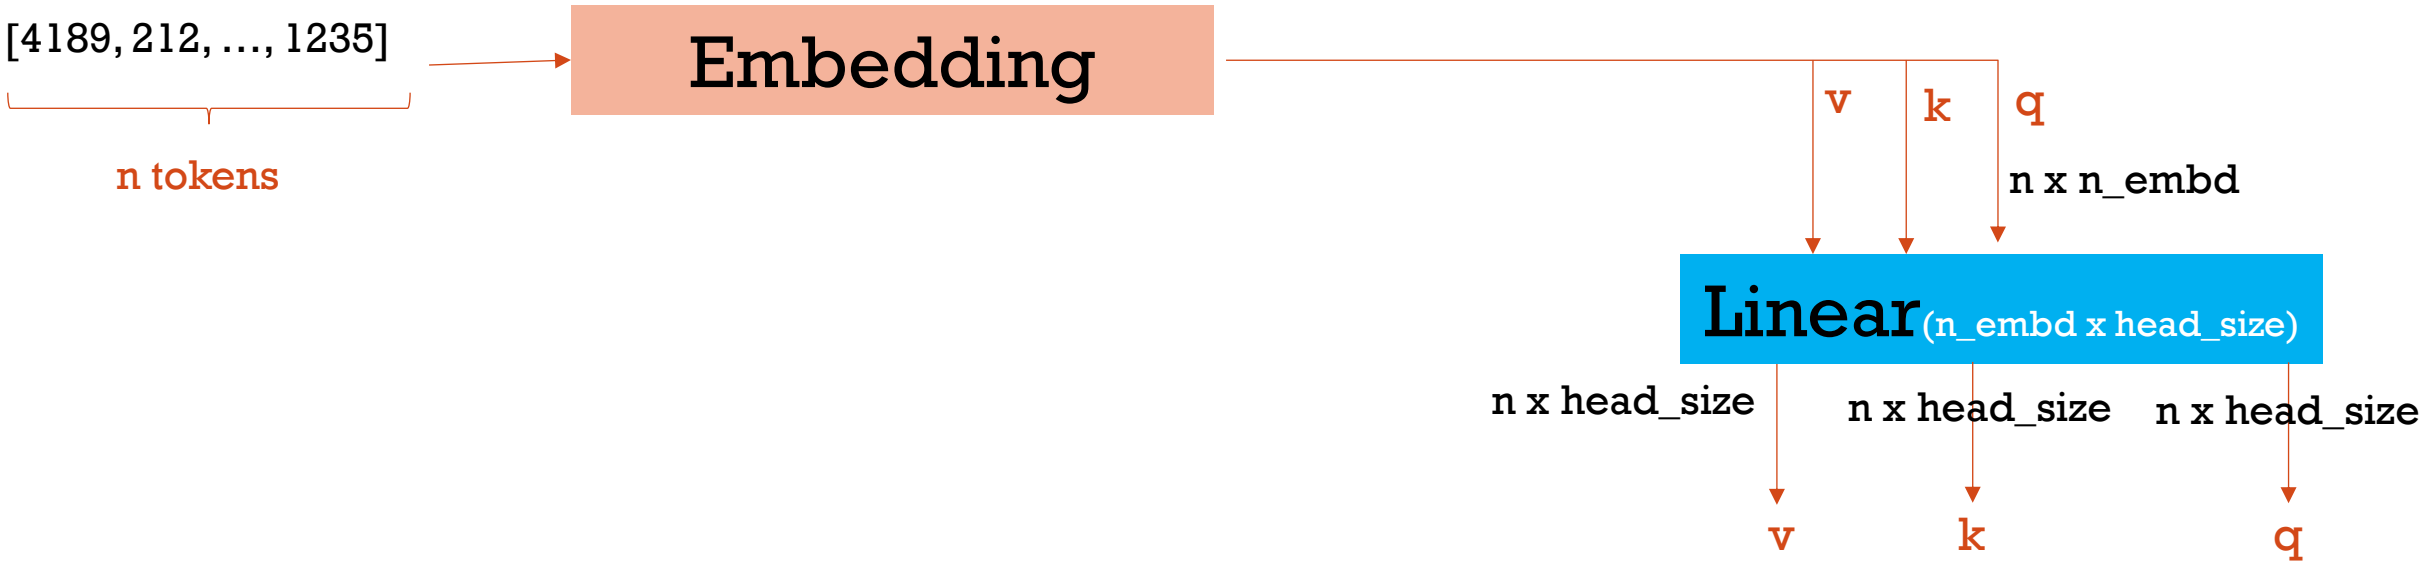
[4189, 212, …, 1235]
n tokens
Embedding
v
k
q
n x n_embd
Linear (n_embd x head_size)
n x head_size
n x head_size
n x head_size
v
k
q

ATTENTION

n x ~~n_embd~~ @ ~~n_embd~~ x head_size = n x head_size

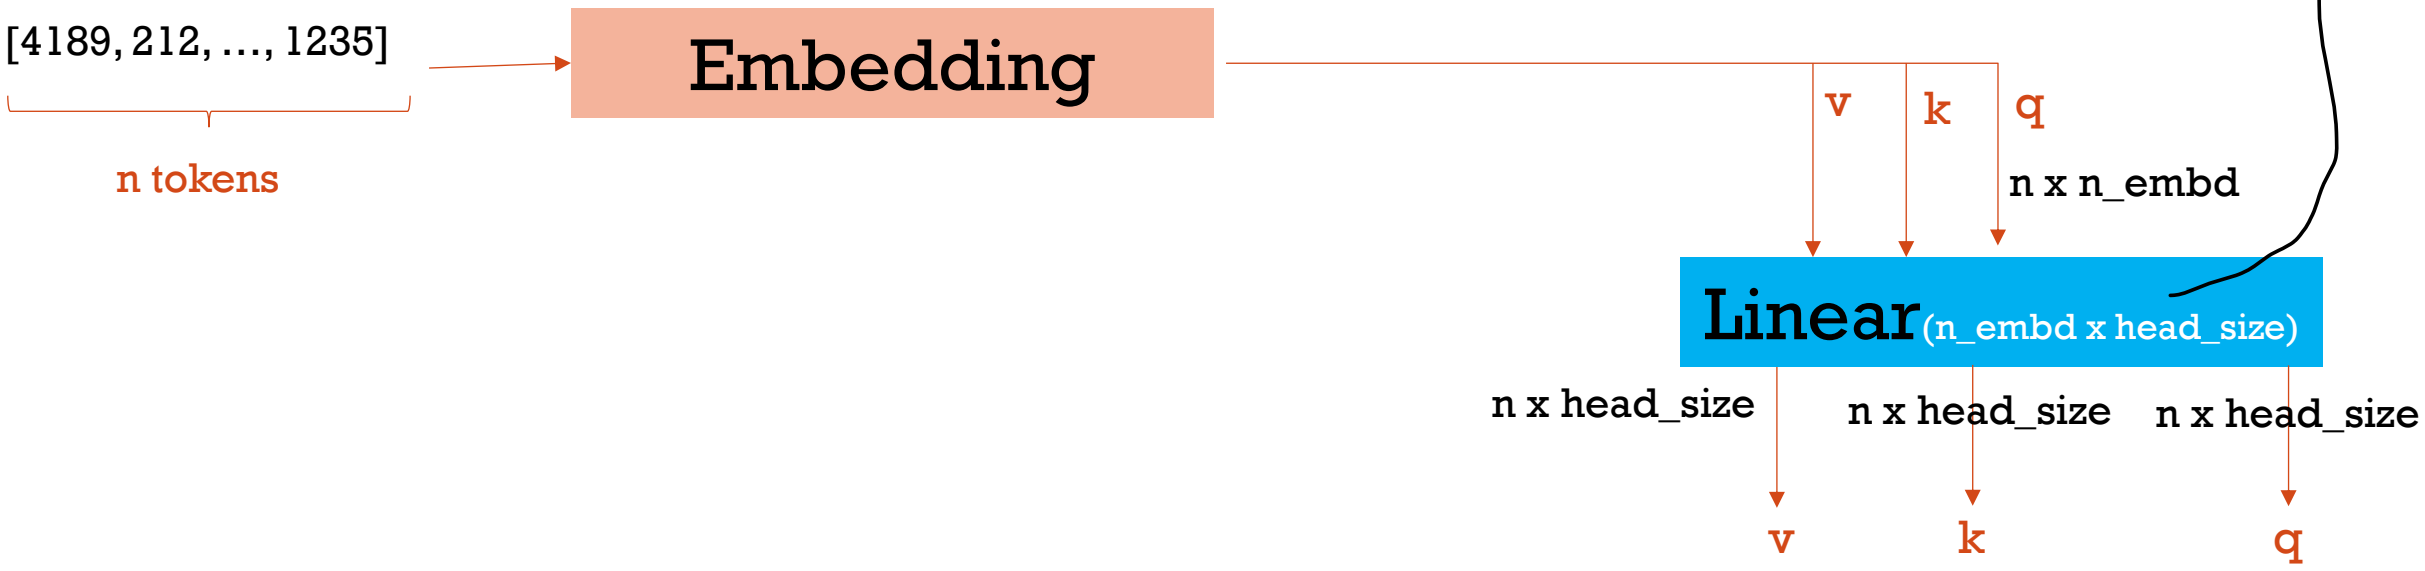

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

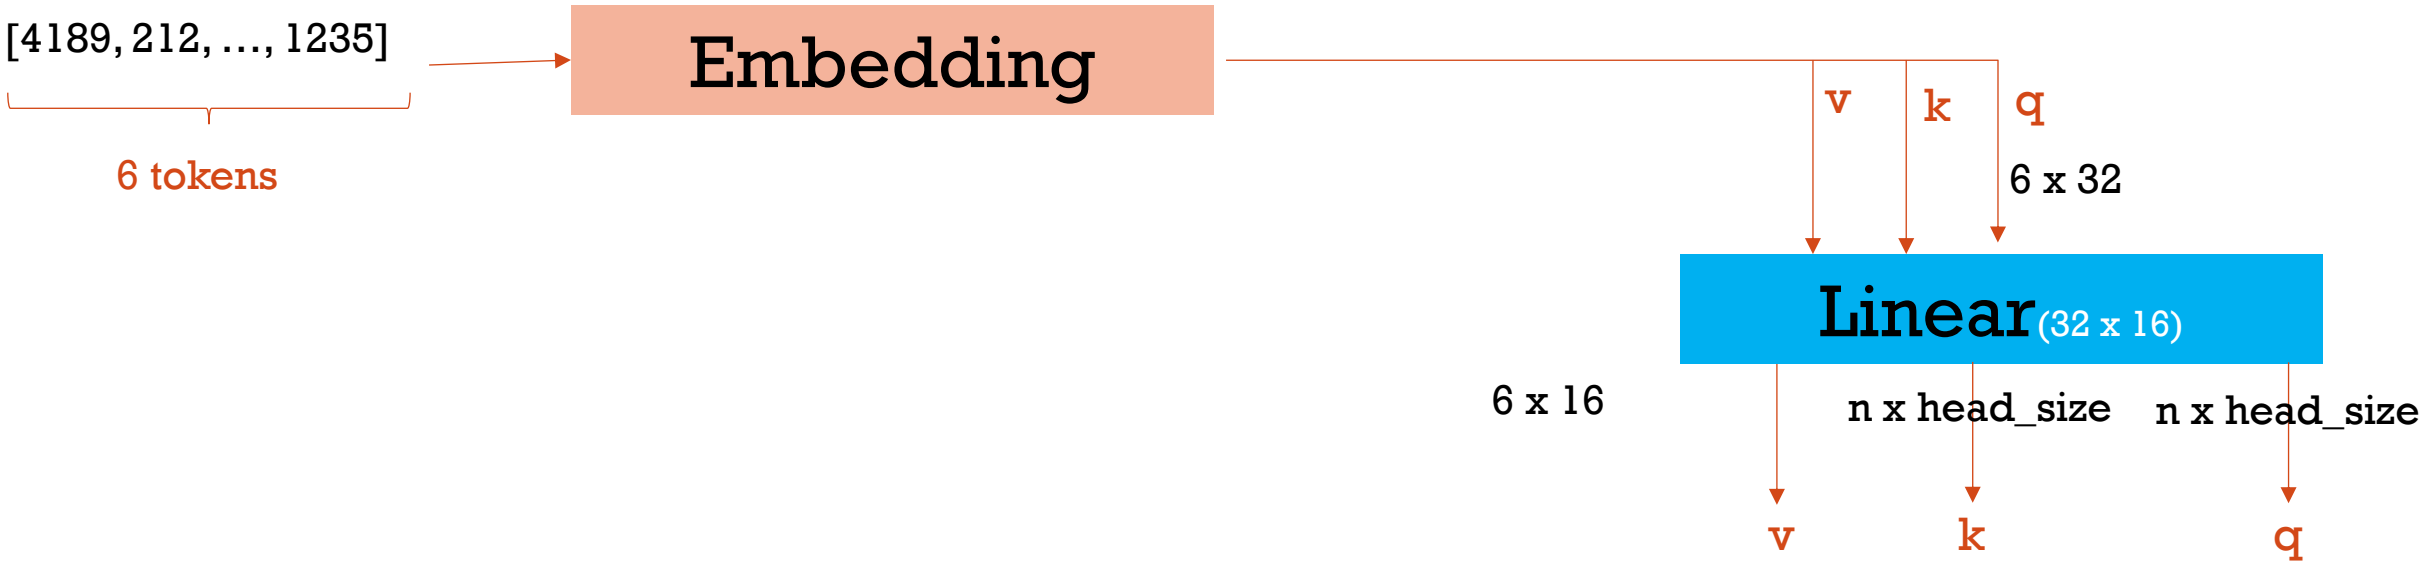

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب						
الذي						
قرأته						
اليوم						
كان						
جيدا						

queries

$$\underbrace{6 \times 16}_{\text{query}} \; @ \; \underbrace{16 \times 6}_{\text{key}} = 6 \times 6$$

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	منخفض	منخفض	**مرتفع**	منخفض	منخفض	**مرتفع**
الذي						
قرأته						
اليوم						
كان						
جيدا						

queries

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	منخفض	منخفض	**مرتفع**	منخفض	منخفض	**مرتفع**
الذي	**مرتفع**	منخفض	**مرتفع**	منخفض	منخفض	منخفض
قرأته						
اليوم						
كان						
جيدا						

queries

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	منخفض	منخفض	**مرتفع**	منخفض	منخفض	**مرتفع**
الذي	**مرتفع**	منخفض	**مرتفع**	منخفض	منخفض	منخفض
قرأته	**مرتفع**	متوسط	منخفض	متوسط	منخفض	منخفض
اليوم						
كان						
جيدا						

queries

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	منخفض	منخفض	**مرتفع**	منخفض	منخفض	**مرتفع**
الذي	**مرتفع**	منخفض	**مرتفع**	منخفض	منخفض	منخفض
قرأته	**مرتفع**	متوسط	منخفض	متوسط	منخفض	منخفض
اليوم	منخفض	منخفض	منخفض	منخفض	منخفض	منخفض
كان						
جيدا						

queries

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	منخفض	منخفض	**مرتفع**	منخفض	منخفض	**مرتفع**
الذي	**مرتفع**	منخفض	**مرتفع**	منخفض	منخفض	منخفض
قرأته	**مرتفع**	متوسط	منخفض	متوسط	منخفض	منخفض
اليوم	منخفض	منخفض	منخفض	منخفض	منخفض	منخفض
كان	**مرتفع**	منخفض	منخفض	منخفض	منخفض	**مرتفع**
جيدا						

queries

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	منخفض	منخفض	**مرتفع**	منخفض	منخفض	**مرتفع**
الذي	**مرتفع**	منخفض	**مرتفع**	منخفض	منخفض	منخفض
قرأته	**مرتفع**	متوسط	منخفض	متوسط	منخفض	منخفض
اليوم	منخفض	منخفض	منخفض	منخفض	منخفض	منخفض
كان	**مرتفع**	منخفض	منخفض	منخفض	منخفض	**مرتفع**
جيدا	**مرتفع**	منخفض	منخفض	منخفض	**مرتفع**	منخفض

queries

ATTENTION

مثال: الكتاب الذي قرأته اليوم كان جيدا

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	0.05	0.1	**0.4**	0.05	0.15	**0.25**
الذي	**0.4**	0.05	**0.4**	0.05	0.05	0.05
قرأته	**0.7**	0.10	0.05	0.05	0.05	0.05
اليوم	0.15	0.15	0.15	0.15	0.20	0.20
كان	**0.4**	0.05	0.05	0.05	0.05	**0.4**
جيدا	**0.4**	0.05	0.05	0.05	**0.4**	0.05

queries

ATTENTION

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	0.05	0.1	**0.4**	0.05	0.15	**0.25**
الذي	**0.4**	0.05	**0.4**	0.05	0.05	0.05
قرأته	**0.7**	0.10	0.05	0.05	0.05	0.05
اليوم	0.15	0.15	0.15	0.15	0.20	0.20
كان	**0.4**	0.05	0.05	0.05	0.05	**0.4**
جيدا	**0.4**	0.05	0.05	0.05	**0.4**	0.05

queries

$$@\ \underbrace{6 \times 16}_{\text{value}} = 6 \times 16$$

ATTENTION

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	0.05	0.1	**0.4**	0.05	0.15	**0.25**
الذي	**0.4**	0.05	**0.4**	0.05	0.05	0.05
قرأته	**0.7**	0.10	0.05	0.05	0.05	0.05
اليوم	0.15	0.15	0.15	0.15	0.20	0.20
كان	**0.4**	0.05	0.05	0.05	0.05	**0.4**
جيدا	**0.4**	0.05	0.05	0.05	**0.4**	0.05

queries

@ 6 x 16 = 6 x 16

value

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

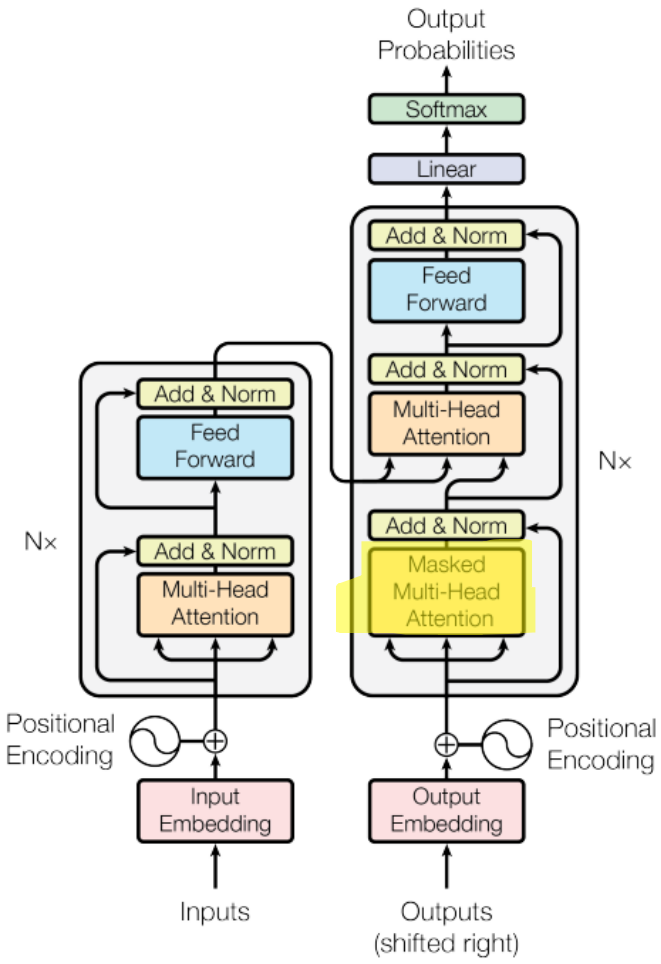

Figure 1: The Transformer - model architecture.

ATTENTION

Masking

keys

	الكتاب	الذي	قرأته	اليوم	كان	جيدا
الكتاب	0.05	**0**	**0**	**0**	**0**	**0**
الذي	**0.4**	0.05	**0**	**0**	**0**	**0**
قرأته	**0.7**	0.05	0.05	**0**	**0**	**0**
اليوم	0.15	0.15	0.15	0.15	**0**	**0**
كان	**0.4**	0.05	0.05	0.05	0.05	**0**
جيدا	**0.4**	0.05	0.05	0.05	**0.4**	0.05

queries

@ 6 x 16 = 6 x 16

value

Attention = (6 x 16 @ 16 x 6) @ 6 x 16

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

ATTENTION

$$\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$$

Attention = softmax($\underbrace{6 \text{ x } 16}_{\text{query}}$ @ $\underbrace{16 \text{ x } 6}_{\text{key}}$) @ $\underbrace{6 \text{ x } 16}_{\text{value}}$ = 6 x 16

softmax($\underbrace{\text{block_size x head_size}}_{\text{query}}$ @ $\underbrace{\text{head_size x block_size}}_{\text{key}}$) @ $\underbrace{\text{block_size x head_size}}_{\text{value}}$ = block_size x head_size

NEXT...TRANSFORMER

(practically)